

Technology Posts Analytics

Implementación de un Pipeline DataOps

Miguel Ángel Hernández Vargas

Escuela Colombiana de Ingeniería

5 de diciembre de 2025

Agenda

- 1 Introducción
- 2 Objetivos
- 3 Arquitectura del Sistema
- 4 Dashboard
- 5 CI/CD y Automatización
- 6 Conclusiones

Contexto del Proyecto

Las redes sociales se han convertido en una de las fuentes principales para identificar tendencias tecnológicas. Sin embargo, trabajar con estos datos presenta desafíos importantes:

- **Volumen:** miles de interacciones por minuto.
- **Ruido:** información no estructurada.
- **Volatilidad:** picos de viralidad impredecibles.

¿Cómo convertir el flujo masivo de datos sociales en un sistema automatizado y preciso?

Se necesita un sistema que asegure calidad y confiabilidad en el monitoreo del desempeño.

Objetivos del Proyecto

Objetivo General

Diseñar e implementar un pipeline DataOps, aplicando principios de automatización, calidad y gobernanza, para analizar la correlación entre la actividad social digital y las métricas de desempeño en el sector tecnológico.

Objetivos Específicos

- ① Automatización:** Implementar procesos de ingestión, transformación y control de calidad de datos.
- ② Rigor Analítico:** Aplicar técnicas de análisis estadístico para validar posibles patrones y relaciones en los datos.
- ③ Observabilidad:** Desarrollar herramientas interactivas para el monitoreo de tendencias y detección de anomalías.
- ④ Gobernanza:** Asegurar la trazabilidad y reproducibilidad mediante versionamiento y CI.

Arquitectura Modular del Pipeline

El sistema orquesta 3 etapas:

① Ingesta:

- **Inicial:** Conexión automatizada a la API de Kaggle.
- **Mecanismo de respaldo:** Detección automática de archivos locales en caso de fallo de red.


② Validación y Calidad:

- **Contratos de Esquema:** Verificación de columnas antes de procesar.
- **Validaciones Estadísticas:** Detección de columnas con varianza cero.
- **Control de Nulos:** Monitoreo de umbrales de completitud.

③ Transformación y Enriquecimiento:

- **Estandarización Temporal:** Unificación de formatos dispares.
- **Imputación:** Manejo estadístico de valores faltantes en métricas de influencia.
- **NLP:** Scoring de sentimiento (VADER) y modelado de tópicos (LDA).

Arquitectura del Sistema



Motor de Análisis Adaptativo

Análisis Confiable y Automatizado

El pipeline no asume la naturaleza de los datos. Ejecuta un Motor de Decisión en tiempo de ejecución:

- **Paso 1:** Test de Normalidad.
- **Paso 2:** Selección de Algoritmo:
 - Si es Normal → Pearson
 - Si No es Normal → Spearman.

Resultado: Métricas confiables que se adaptan a la naturaleza de los datos.

Se desarrolló una interfaz para explorar resultados de manera interactiva:

Funcionalidades Implementadas

- **Alertas Automáticas:** Detección de cambios inusuales en el tráfico de datos y caídas importantes en el sentimiento de las publicaciones.
- **Visualización temporal:** Muestra datos históricos en una línea de tiempo.
- **Análisis Estadístico:** Permite ver correlaciones entre variables.
- **Exploración Interactiva:**
 - Filtrado por fecha y plataforma.
 - Visualización de longitud de texto vs sentimiento y temas principales (LDA).

Pipeline de Integración Continua (GitHub Actions)

Para asegurar la reproducibilidad y calidad del pipeline, se implementó un flujo de CI automatizado:

Workflow Automático

- ① **Setup:** Instalación de dependencias y uso de caché para acelerar ejecuciones.
- ② **Pruebas Unitarias:** Ejecución de la suite pytest (33 tests exitosos).
- ③ **Verificación Rápida:** Test completo del pipeline para asegurar que todos los componentes funcionen correctamente.

Conclusiones

- **Continuidad del Pipeline:** La arquitectura diseñada permite que el flujo de datos siga funcionando incluso si hay problemas con servicios externos, asegurando que el análisis no se interrumpa.
- **Análisis Estadístico Confiable:** Las métricas de interacción en redes muestran distribuciones no normales. Usar pruebas no paramétricas (Spearman) ayudó a obtener resultados más precisos y evitar interpretaciones erróneas.
- **Arquitectura Modular:** La separación en capas (Ingesta, Transformación, Análisis) facilitó la integración de controles de calidad y deja abierta la posibilidad de incorporar nuevas fuentes de datos de forma sencilla.

Gracias

Gracias

Repositorio: <https://github.com/Miguelhv27/technology-posts-pipeline>